

**BABEŞ-BOLYAI UNIVERSITY, CLUJ-NAPOCA,
ROMANIA**

FACULTY OF MATHEMATICS AND COMPUTER SCIENCE

Face2Learn

– MIRPR Report 2025 –

Team members:

Bucur Victor Sever, Popoviciu Luca, Porcar Cezar, Potra-Raţiu Darius, Preduca Matei

2025

Rezumat

Aplicația reprezintă un sistem inteligent bazat pe inteligență artificială, denumit **Face2Learn**, care combină modele de limbaj mari (LLM), sinteză vocală (TTS) și animație facială pentru a crea o experiență de învățare naturală și interactivă. Scopul proiectului este de a transforma informațiile academice în explicații conversaționale, vizuale și auditive, crescând astfel implicarea, accesibilitatea și retenția informației. Performanța sistemului este evaluată prin acuratețea răspunsurilor, latența end-to-end și naturalitatea percepută a avatarului.

Cuprins

1	Descrierea problemei rezolvate cu ajutorul AI	3
1.1	Contextul problemei	3
1.2	Scopul și importanța problemei	3
1.3	Utilizatorii sistemului	3
1.4	Datele de intrare și ieșire	4
1.5	Tipurile de date utilizate	4
1.6	Măsurarea performanței sistemului AI	4
2	Related work and useful tools and technologies	5
2.1	1. LoRA (Low-Rank Adaptation)	5
2.2	2. QLoRA	5
2.3	3. llama.cpp	5
2.4	4. TinyLLM (Phi, Mistral, TinyLLaMA)	6
2.5	5. RAGFlow	6
2.6	6. RAG-Anything	6
2.7	7. Whisper TTS	6
2.8	8. Piper	6
2.9	9. Wav2Lip	6
2.10	10. SadTalker	7
3	Evaluarea sistemului RAG utilizat în Face2Learn	8
3.1	Descrierea și explorarea datelor (EDA)	8
3.2	Descrierea algoritmului inteligent	9
3.3	Metodologia experimentală	9
3.4	Rezultate obținute	10
3.5	Analiza finală	10
4	Re-Evaluarea sistemului RAG utilizat în Face2Learn	11
4.1	Motivația re-evaluării	11
4.2	Actualizarea modelului de generare	11
4.2.1	Migrarea la Meta-Llama-3-8B-Instruct	11
4.2.2	Motivația schimbării	12

4.3	Actualizarea infrastructurii de rulare	12
4.3.1	De la LM Studio la llama.cpp	12
4.4	Actualizarea fluxului multimedia	12
4.4.1	Generarea avatarului cu SadTalker	12
4.4.2	TTS cu Piper	13
4.5	Îmbunătățirea promptului	13
4.6	Noua metodologie experimentală	13
4.6.1	Date de evaluare	13
4.6.2	Metrici utilizate	13
4.7	Rezultate obținute pe setul de 50 de întrebări	14
4.8	Rezultate obținute pe setul de 200 de întrebări	14
4.9	Analiza finală	14

Capitolul 1

Descrierea problemei rezolvate cu ajutorul AI

1.1 Contextul problemei

Sistemele educaționale tradiționale se bazează predominant pe text și prelegeri statice. În contextul actual al digitalizării, apare nevoia de metode de predare interactive, personalizate și accesibile. Proiectul **Face2Learn** propune utilizarea inteligenței artificiale multimodale pentru a crea un asistent virtual care explică concepte academice prin vorbire și expresii faciale sincronizate.

Modelul AI poate înțelege întrebări formulate în limbaj natural, poate accesa informații relevante din materiale educaționale și poate furniza răspunsuri clare, exprimate vocal și vizual printr-un avatar animat.

1.2 Scopul și importanța problemei

Scopul principal este de a transforma procesul de învățare într-o experiență naturală, captivantă și accesibilă. Importanța proiectului derivă din:

- creșterea **engagement-ului** și motivației elevilor/studentilor;
- asigurarea **accesibilității** pentru persoane cu deficiențe de vedere sau auz;
- sprijinirea cadrelor didactice prin automatizarea explicațiilor și a sesiunilor de Q&A;
- posibilitatea **învățării personalizate** în ritmul fiecărui utilizator.

1.3 Utilizatorii sistemului

- **Studenți și elevi** – folosesc avatarul AI pentru explicații și recapitulări;
- **Profesori și tutori** – utilizează sistemul pentru demonstrații și asistență automată;

- **Instituții educaționale** – integrează soluția pentru suport didactic 24/7;
- **Persoane cu dizabilități** – beneficiază de conținut multimodal adaptat.

1.4 Datele de intrare și ieșire

Date de intrare:

- întrebări formulate în limbaj natural (text sau voce);
- documente educaționale (manuale, cursuri, notițe);
- preferințe ale utilizatorului (limbă, voce, tonalitate).

Date de ieșire:

- răspuns text generat de LLM;
- voce sintetică naturală generată prin TTS;
- videoclip animat cu avatar sincronizat cu vorbirea.

1.5 Tipurile de date utilizate

- corpusuri textuale academice și explicații didactice;
- înregistrări audio pentru antrenarea TTS;
- imagini/video cu expresii faciale pentru sincronizare (lip-sync);
- embeddings semantice pentru căutare contextuală (RAG).

1.6 Măsurarea performanței sistemului AI

Performanța sistemului este evaluată prin indicatori cantitativi și calitativi:

- **Acuratețea răspunsurilor** – procentul de răspunsuri corecte;
- **Timpul mediu de răspuns** – durata procesării end-to-end;
- **Calitatea animației** – gradul de sincronizare buze-vorbire;
- **Consum de resurse** – memorie și timp de inferență.

Capitolul 2

Related work and useful tools and technologies

Această secțiune prezintă zece proiecte și tehnologii relevante pentru construcția unui avatar AI educațional. Pentru fiecare sunt menționate tipul datelor folosite, algoritmii utilizați, performanțele și tehnologiile implicate.

2.1 1. LoRA (Low-Rank Adaptation)

Date: text educațional.

Algoritmi: fine-tuning eficient al LLM-urilor prin adaptare low-rank.

Performanță: îmbunătățire a acurateței cu cost redus.

Tehnologii: PyTorch, Hugging Face, GitHub open-source.

2.2 2. QLoRA

Date: corpus text.

Algoritmi: fine-tuning cu cuantizare pentru reducerea memoriei.

Performanță: menține calitatea modelului la 4-bit.

Tehnologii: Transformers, bitsandbytes, Hugging Face.

2.3 3. llama.cpp

Date: text.

Algoritmi: inferență locală pentru modele cuantizate.

Performanță: latență redusă pe CPU.

Tehnologii: C++, GGUF models, GitHub.

2.4 4. TinyLLM (Phi, Mistral, TinyLLaMA)

Date: text.

Algoritmi: modele compacte pentru rulare eficientă.

Performanță: raport bun între viteză și acuratețe.

Tehnologii: PyTorch, Hugging Face.

2.5 5. RAGFlow

Date: documente și note de curs.

Algoritmi: RAG (retrieval augmented generation).

Performanță: răspunsuri mai relevante.

Tehnologii: LangChain, FAISS, GitHub.

2.6 6. RAG-Anything

Date: fișiere locale (PDF, text).

Algoritmi: flux simplificat RAG.

Performanță: acces rapid la surse externe.

Tehnologii: Python, Streamlit, GitHub.

2.7 7. Whisper TTS

Date: corpusuri audio și transcripții text.

Algoritmi: model neural de sinteză vocală bazat pe arhitectura Whisper.

Performanță: voce naturală și suport multilingv.

Tehnologii: PyTorch, Whisper TTS API (OpenAI), Hugging Face, GitHub.

2.8 8. Piper

Date: audio/text.

Algoritmi: TTS optimizat pentru dispozitive edge.

Performanță: latență foarte mică.

Tehnologii: Rust, on-device inference.

2.9 9. Wav2Lip

Date: video + audio.

Algoritmi: lip-sync bazat pe rețele CNN.

Performanță: aliniere buze-vorbire realistă.

Tehnologii: PyTorch, OpenCV, GitHub.

2.10 10. SadTalker

Date: imagine + audio.

Algoritmi: talking-face generation dintr-o singură imagine.

Performanță: expresii faciale naturale.

Tehnologii: PyTorch, DeepFace, GitHub.

Capitolul 3

Evaluarea sistemului RAG utilizat în Face2Learn

3.1 Descrierea și explorarea datelor (EDA)

Pentru evaluarea componentei de **întrebare-răspuns** din sistemul Face2Learn, a fost creat manual un set de date format din **50 de perechi întrebare-răspuns**. Fiecare întrebare a fost extrasă din conținutul manualului `manual2022.pdf`, iar răspunsul aferent reprezintă transcrierea exactă a fragmentului relevant.

Structura fișierului de date (`evaluare.json`):

```
[
  {
    "intrebare": "Ce reprezintă un segment orientat?",
    "raspuns_asteptat": "un segment ... unde s-a precizat originea si extremitatea"
  },
  ...
]
```

Preprocesare:

- Eliminarea diacriticelor pentru uniformitate.
- Conversia la litere mici și eliminarea spațiilor multiple.
- Nu s-a aplicat tokenizare, deoarece evaluarea folosește similaritate semantică și ROUGE.

Explorare sumară:

- Număr total de exemple: 100;
- Lungime medie întrebare: 9 cuvinte;

- Lungime medie răspuns: 12 cuvinte;
- Domeniu: concepte geometrice (vectori, segmente, egalitate etc.);
- Tip date: text scurt, conceptual – ideal pentru evaluarea unui sistem RAG.

3.2 Descrierea algoritmului inteligent

Algoritm ales: *Retrieval-Augmented Generation (RAG)*.

Motivație: Arhitectura RAG combină avantajele modelelor de căutare contextuală (retrieval) cu cele de generare (generation), permițând sistemului să răspundă coerent pe baza unui context relevant extras dintr-o bază de cunoștințe (PDF-ul cursului). Această abordare elimină necesitatea antrenării unui model mare de la zero, reducând costurile și riscul de halucinații.

Componente principale:

- **Retrieval:** Model de embedding `thenlper/gte-small` (din `sentence-transformers`) și indexare cu `faiss-cpu`. Scopul este transformarea fragmentelor PDF în vectori semantici și extragerea celor mai relevante pasaje.
- **Generation:** Modelul `mistral-7b-instruct-v0.3.Q4_K_M.gguf`, rulat local prin LM Studio. Acesta generează răspunsul final folosind contextul returnat de retriever.

Librării utilizate: `langchain`, `sentence-transformers`, `faiss-cpu`, `numpy`, `transformers`, `sklearn.metrics`.

3.3 Metodologia experimentală

Împărțirea datelor: Setul de 50 de exemple a fost folosit în întregime ca **set de test**. Scopul principal a fost evaluarea sistemului complet (RAG + LLM), nu antrenarea unui model nou.

Hiperparametri utilizați:

Parametru	Valoare	Descriere
<code>chunk_size</code>	256	Lungimea unui fragment de text la indexare
<code>chunk_overlap</code>	25	Suprapunerea dintre fragmente consecutive
<code>k</code>	4	Numărul de pasaje returnate de retriever
<code>temperature</code>	0.3	Controlul creativității LLM-ului

Metrici de evaluare:

- **ROUGE-L (F1):** măsoară suprapunerea exactă între răspunsul generat și cel așteptat;
- **Similaritate Semantică (Cosine Similarity):** măsoară apropierea conceptuală dintre răspunsuri, folosind embedding-urile `gte-small`.

3.4 Rezultate obținute

Metrică	Valoare medie
ROUGE-L (F1)	20.61%
Similaritate Semantică	90.24%

Interpretare:

- Scorul semantic ridicat (90%) indică faptul că sistemul a înțeles corect întrebările și a generat răspunsuri cu același sens;
- Scorul ROUGE redus (20%) arată că modelul preferă să reformuleze textul în loc să reproducă exact pasajul original.

Exemple reprezentative:

Caz	Întrebare	Răspuns așteptat	Răspuns generat	Observație
1	Segment orientat	un segment ... cu origine și extremitate	o porțiune ... cu direcție asignată	sens corect, formulare diferită
2	Egalitate segmente	A=C și B=D	A=D și B=C	halucinație (ordine inversată)
3	Vector liber	o clasă de echivalență	o familie de vectori legați	parafrizare semantică

3.5 Analiza finală

Diferența semnificativă dintre scorurile ROUGE și Similaritate Semantică evidențiază o problemă frecventă în sistemele RAG:

- Modelul LLM **înțelege contextul**, dar nu respectă instrucțiunea „răspunde exclusiv pe baza textului oferit”;
- Răspunsurile sunt logic corecte, dar lexical diferite;
- În unele cazuri apar **halucinații minore** (exemplul #2).

Concluzie parțială: Rezultatele arată că sistemul RAG implementat are o **performanță semantică excelentă**, dar necesită îmbunătățiri și aplicarea unei penalizări de diversitate în prompt.

Capitolul 4

Re-Evaluarea sistemului RAG utilizat în Face2Learn

4.1 Motivația re-evaluării

În urma evaluării inițiale prezentate în capitolul anterior, au fost identificate limitări în ceea ce privește acuratețea lexicală, consistența răspunsurilor și stabilitatea infrastructurii de inferență. Pentru a îmbunătăți performanța și a reduce halucinațiile, sistemul a fost supus unei optimizări majore, incluzând:

- schimbarea modelului LLM utilizat în etapa de generare;
- migrarea infrastructurii de la LM Studio la `llama.cpp` cu accelerare GPU;
- ajustarea promptului pentru răspunsuri mai clare și mai „user-friendly”;
- introducerea unei noi metrice de evaluare (BLEU score);
- extinderea setului de testare la 200 de întrebări.

Obiectivul principal al acestei re-evaluări este măsurarea impactului modificărilor asupra performanței sistemului RAG în ansamblu.

4.2 Actualizarea modelului de generare

4.2.1 Migrarea la Meta-Llama-3-8B-Instruct

Modelul inițial, `mistral-7b-instruct`, a fost înlocuit cu **Meta-Llama-3-8B-Instruct**, un model modern de 8 miliarde de parametri, optimizat pentru:

- urmărirea instrucțiunilor (*instruction-following*);
- capacități bune de reasoning și explicare;

- coerență ridicată pe contexte scurte și medii;
- generare stabilă în aplicații conversaționale.

Modelul a fost rulat în format `GGUF` folosind `llama.cpp`, beneficiind de suport GPU, ceea ce a redus semnificativ latența inferenței.

4.2.2 Motivația schimbării

Performanța suboptimală a modelului anterior în ceea ce privește coerența și structura răspunsurilor a determinat trecerea la un model mai robust, cu accent pe:

- reducerea halucinațiilor;
- menținerea unui limbaj mai natural;
- răspunsuri explicate mai bine, pe nivele (răspuns scurt + explicație + referințe).

4.3 Actualizarea infrastructurii de rulare

4.3.1 De la LM Studio la llama.cpp

LM Studio a fost înlocuit cu `llama.cpp`, care oferă:

- performanță ridicată în inferență locală;
- suport pentru GPU (CUDA);
- consum redus de memorie;
- flexibilitate crescută pentru configurarea pipeline-ului RAG.

Această schimbare a permis rularea modelului la o viteză superioară și o stabilitate mai mare în fluxurile de generare.

4.4 Actualizarea fluxului multimedia

Pentru componenta de avatar și sinteză vocală au fost adoptate tehnologii noi:

4.4.1 Generarea avatarului cu SadTalker

SadTalker a fost utilizat pentru generarea unui avatar animat pe baza unei imagini statice și a unui fișier audio. Modelul oferă:

- sincronizare buze-vorbire realistă;
- expresivitate ridicată a feței;
- reproducerea mișcărilor naturale ale capului.

4.4.2 TTS cu Piper

Modelul Piper a fost ales pentru sinteza vocală datorită:

- latenței foarte reduse;
- clarității ridicate a vocii;
- suportului avansat pentru limba română.

4.5 Îmbunătățirea promptului

Promptul utilizat pentru generare a fost extins și structurat astfel încât modelul să ofere răspunsuri pe trei niveluri:

1. **răspuns scurt și direct**, orientat pe întrebare;
2. **explicație detaliată**, adaptată stilului conversațional;
3. **referințe**, care indică secțiunea sau capitolul din document unde se găsește răspunsul complet.

Această structură a redus semnificativ ambiguitățile și a îmbunătățit calitatea percepută a răspunsurilor.

4.6 Noua metodologie experimentală

4.6.1 Date de evaluare

Două seturi de test au fost folosite pentru re-evaluare:

- același set inițial de **50 de întrebări**;
- întregul set de **200 de întrebări** din documentul original.

4.6.2 Metrice utilizate

Comparativ cu evaluarea anterioară, a fost introdusă o metrică suplimentară:

- **Similaritate Semantică (Cosine Similarity)**;
- **ROUGE-L (F1)**;
- **BLEU Score** – măsoară precizia lexicală și n-gram.

4.7 Rezultate obținute pe setul de 50 de întrebări

Metrică	Valoare
Similaritate Semantică	90.81%
ROUGE-L	23.19%
BLEU Score	5.63%

Observații:

- scorurile cresc semnificativ față de evaluarea inițială;
- structura promptului contribuie la o acuratețe semnificativ îmbunătățită;
- reformulările naturale ale modelului explică BLEU-ul relativ modest.

4.8 Rezultate obținute pe setul de 200 de întrebări

Metrică	Valoare
Similaritate Semantică	88.92%
ROUGE-L	16.65%
BLEU Score	2.95%

Interpretare:

- scăderea scorurilor este normală pentru un set de test mult mai diversificat;
- consistența semantică rămâne ridicată, confirmând robustețea sistemului;
- performanța indică o generalizare mai bună decât în etapa inițială.

4.9 Analiza finală

Comparativ cu evaluarea inițială:

- acuratețea semantică s-a îmbunătățit cu aproximativ 1.5–2%;
- ROUGE-L a crescut în re-evaluarea pe 50 de întrebări, indicând o suprapunere textuală mai mare;
- răspunsurile sunt mai bine structurate și conțin referințe utile;
- modelul Meta-Llama-3-8B-Instruct a redus halucinațiile și a crescut consistența;
- pipeline-ul multimedia produce rezultate mai naturale prin SadTalker și Piper.

Concluzii

Proiectul „Face2Learn” oferă o abordare inovatoare de integrare a AI multimodal (text, voce, video) în domeniul educației. Combinația între LLM-uri optimizate, TTS și animație sincronizată contribuie la îmbunătățirea experienței de învățare, făcând-o mai naturală, mai interactivă și mai accesibilă.